

1. Tóm tắt và bối cảnh

Dự án xây dựng một hệ thống gợi ý hoàn chỉnh trên dữ liệu quy mô lớn, áp dụng các kỹ thuật collaborative filtering, matrix factorization, content-based và ensemble đã học.

Dự án được chia thành ba giai đoạn (Phase) chính theo trình tự thời gian phát triển:

- **Phase 1:** Triển khai pipeline đầy đủ trên Amazon Reviews 2018, thử nghiệm hai category Electronics và Home & Kitchen. Đây là giai đoạn học hỏi và phát hiện vấn đề.
- **Phase 2:** Sau khi nhận thấy hạn chế thực tiễn của kết quả trên Amazon, chuyển sang dataset Goodreads UCSD Book Graph (15.7M reviews), xây lại pipeline cho phù hợp với đặc thù dữ liệu sách.
- **Phase 3 (đang tiến hành):** Mở rộng kết quả Goodreads bằng cách kết hợp với thuật toán chainRec (Wan & McAuley, RecSys'18) để tạo contribution mới có giá trị nghiên cứu.

Báo cáo này tổng hợp toàn bộ hành trình ba phase, bao gồm cả các thất bại và bài học rút ra, không chỉ trình bày kết quả cuối cùng.

2. Phase 1 – Hệ thống gợi ý trên Amazon Reviews 2018

2.1 Tổng quan dữ liệu và quy trình tiền xử lý

Amazon Reviews 2018 là dataset được sử dụng rộng rãi trong cộng đồng RecSys, với hàng chục triệu review trải dài qua nhiều category sản phẩm. Dự án sử dụng hai category đại diện cho hai kiểu thị trường khác nhau:

Category	Số reviews gốc	Sau k-core 5	Users	Items	Sparsity
Electronics	≈14M	5,517,640	609K	145K	99.99%
Home & Kitchen	13,824,810	5,622,812	647K	170K	99.9949%

Dữ liệu gốc trải qua 7 bước làm sạch tổng hợp: loại bỏ HTML và emoji, chuẩn hóa unicode, parse và validate timestamp, drop reviews có rating bằng 0 hoặc text rỗng, deduplicate theo (user_id, item_id, timestamp), filter review quá ngắn (<10 tokens) và quá dài (>2000 tokens). Output được lưu dưới dạng partitioned parquet nén zstd và host trên HuggingFace tại [datdong2004/amazonNew-cleaned](#). Mỗi category được load riêng để tránh nổ RAM trên Kaggle (giới hạn 30GB).

Phân bổ rating lệch nặng

EDA trên Home & Kitchen cho thấy distribution rating cực kỳ lệch: 5 sao chiếm ~65.5% toàn bộ reviews, trong khi 1-2 sao chỉ chiếm <10%. Đây là đặc trưng chung của e-commerce — khách hàng không hài lòng thường chọn không review (silent dissatisfaction), trong khi khách hàng rất hài lòng tích cực để lại đánh giá tốt. Hệ quả là bất kỳ mô hình nào dự đoán theo global mean sẽ bias mạnh về phía rating cao.

2.2 Pipeline 5 stage

Pipeline được thiết kế module hóa, mỗi stage có artifact riêng để tái sử dụng:

Stage	Vai trò	Output chính
Stage 0	Canonical data + Baseline	train.parquet, test.parquet, baseline (Bayesian shrinkage)
Stage 1	Cold-start profiling	User groups: new/cold/medium/warm
Stage 2	Feature Engineering	item_profiles (128-dim), user_profiles, M_norm, C_implicit
Stage 3	4 mô hình hỗ trợ	Model A/B/C/D predictions
Stage 4	Ensemble & meta-learning	16 candidates → winner ridge_positive

Stage	Vai trò	Output chính
Stage 5	Evaluation mở rộng	RMSE, MAE, Precision@K, NDCG@K, Coverage

Nguyên tắc không rò rỉ dữ liệu

Pipeline tuân thủ nghiêm ngặt nguyên tắc anti-leakage: temporal split thay vì random split, mọi fit và transform chỉ chạm tập train, hyperparameter tuning chỉ dùng validation OOF, test set được dự đoán đúng một lần duy nhất để báo cáo cuối. Stage 0 chia train/test 80/20 theo cutoff date 15/05/2017 cho Home & Kitchen, mô phỏng đúng kịch bản thực tế dùng quá khứ dự đoán tương lai.

Bayesian shrinkage cho baseline

Baseline được nâng cấp với Bayesian shrinkage: $\text{pred} = (\text{user_mean} \times n_u + \text{global_mean} \times \lambda) / (n_u + \lambda)$, kéo các user/item ít tương tác về global mean. Điều này tạo ra một baseline mạnh hơn baseline trung bình thô và đặt ngưỡng cao hơn để các model phức tạp phải vượt qua.

2.3 Bốn mô hình hỗ trợ ở Stage 3

Stage 3 implement 4 paradigm khác nhau, mỗi paradigm tận dụng một loại tín hiệu riêng:

Model	Paradigm	Ý tưởng chính	Đặc điểm kỹ thuật
A. Item-Item CF	Memory-based CF	Cosine similarity giữa cột item trong M_{norm}	Top-k neighbors + shrinkage cho cặp ít co-raters; fallback baseline khi không đủ neighbors
B. MF-SGD	Latent factor	UV decomposition trên residual (R - baseline)	Numba JIT tăng tốc 10-50x; n_{factors} 20-50; learning rate decay 0.95/epoch
C. Content-Based	Item features	$\text{pred} = \text{baseline} + \text{residual_scale} \times \cosine(\text{user_profile}, \text{item_profile})$	Dùng artifacts SVD-128 từ Stage 2; rating centering quanh 3.5
D. ALS Implicit	Implicit MF	Học từ ma trận nhị phân ($1 = \text{đã rate}$), confidence $c = 1 + \alpha \times \text{interaction}$	Thư viện implicit; residual fusion vào baseline

Tối ưu hóa quan trọng – Numba JIT cho MF-SGD

Model B ban đầu chạy SGD bằng Python pure cực chậm (1 epoch ~30 phút trên 5M triplets). Sau khi compile bằng Numba JIT, tốc độ tăng 10-50x, cho phép grid search thực tế trên (n_{factors} , lr, reg, n_{epochs}) — đây là cải tiến đã chứng minh giá trị.

2.4 Ensemble và meta-learning ở Stage 4

Stage 4 thử 16 candidates trên OOF validation, chia thành 8 nhóm:

- Single models (5 baselines: baseline + Model A/B/C/D)
- Manual blends ($0.5 \times B + 0.5 \times C$, $0.6 \times B + 0.4 \times D$, ...)
- Grid blends (duyệt simplex weights)
- Residual blend: $\text{base} + \sum w_i \times (\text{model}_i - \text{base})$
- Ridge positive (constraint không âm, sum-to-one)
- Meta-feature Ridge / ElasticNet (12 meta-features)
- HistGradientBoosting Residual
- Group-aware Ridge (9 nhóm user $\times$ item activity)

Selection rule: chọn theo OOF RMSE, sau đó MAE — không nhìn test. Test chỉ chạm đúng một lần để báo cáo cuối.

2.5 Kết quả thực nghiệm trên Electronics & Home/Kitchen

Electronics – Single models trên test_warm

Model	RMSE	MAE	Ghi chú
Baseline	1.21344	0.92511	Reference
Model A (Item-CF)	1.21537	0.92490	Tệ hơn baseline — fallback rate 99.4%
Model B (MF-SGD)	1.21267	0.86822	Best single — MAE cải thiện 6.2%
Model C (Content)	1.21344	0.92511	residual_scale tune ra 0.0 $\rightarrow$ bằng baseline
Model D (ALS)	1.21344	0.92480	Cải thiện không đáng kể

Electronics – Ensemble winner: ridge_positive_base_b_c_d

Component	Weight
Model B (MF-SGD)	57.5%
Model D (ALS)	25.0%
Baseline	8.8%
Model C (Content)	8.8%

Final test: RMSE 1.19943 (-1.15%), MAE 0.89474 (-3.28%) so với baseline.

Home & Kitchen – Single models trên test_warm

Model	RMSE	MAE	Ghi chú
Baseline	1.1442	0.8552	Reference
Model A	1.1442	0.8551	≈ baseline (shrinkage=10, conservative)
Model B	1.1493	0.8049	RMSE tăng nhẹ nhưng MAE cải thiện mạnh nhất
Model C	1.1476	0.8859	Cải thiện rõ trên rating thấp 1–3 sao
Model D	1.1442	0.8551	Signal ALS quá yếu ($\sim \pm 0.003$)

Home & Kitchen – Bài học validation methodology

Model	OOF RMSE	Test RMSE	Test MAE
HGBR (selected by OOF)	1.0879	1.1389	0.8567
Ridge positive	1.1342	1.1358	0.8380

Insight quan trọng: validation RMSE tốt nhất (HGBR với 1.0879) lại không phải model tốt nhất trên test (1.1389 — kém Ridge 1.1358). Ridge đơn giản tổng quát hóa tốt hơn — confirm lại bài học từ Electronics: model phức tạp overfit validation.

2.6 Stage 5 – Ranking metrics và thất bại quan trọng

Stage 5 mở rộng evaluation từ rating-centric (RMSE/MAE) sang ranking-aware metrics quan trọng hơn cho bài toán recommendation thực tế. Eval chạy trên Electronics với 275,300 users được đánh giá (41,563 bị skip do không có item relevant trong test):

Kết quả Full Catalog Ranking (Model B latent factors)

K	Precision@K	Recall@K	NDCG@K	Hit@K
5	0.0000	0.0001	0.0001	0.0002
10	0.0000	0.0001	0.0001	0.0004
20	0.0001	0.0004	0.0001	0.0010

Catalog Coverage @ top-20

Chỉ số	Giá trị
Unique items được recommend	2,239
Total catalog	143,281
Coverage	1.56%

Phân tích thất bại

Đây là kết quả gây sốc và là bước ngoặt của dự án. Full Catalog Ranking gần như bằng 0 ở mọi K, nghĩa là khi yêu cầu model gợi ý từ toàn bộ 143K items, model gần như không bao giờ chọn được item mà user thực sự thích. Đồng thời, coverage chỉ 1.56% — model luôn recommend cùng một vài nghìn item phổ biến, bỏ qua 98.4% catalog.

Trong khi đó, Within-Test ranking (chỉ rank lại các item user đã có trong test) đạt gần như hoàn hảo (NDCG@10 = 0.9799, Hit@10 = 1.0). Đây là bằng chứng rõ ràng rằng:

- Model học tốt rating của các (user, item) đã có interaction.
- **Nhưng hoàn toàn không có khả năng discover item mới phù hợp từ catalog đầy đủ.**

Nói cách khác, RMSE 1.20 nhìn có vẻ tốt nhưng vô nghĩa với bài toán recommendation thực tế. Đây chính là lý do khiến dự án phải đánh giá lại lựa chọn dataset và phương pháp.

3. Phân tích vấn đề và quyết định chuyển dataset

3.1 Đặc thù của Amazon Reviews

Sau Stage 5 thất bại, dự án phân tích sâu hơn distribution của Amazon Electronics:

Phân khúc	Tỷ lệ	Số items	Tính khả thi
Massive tier (>1000 reviews)	0.6%	1,417 items	Embedding chất lượng cao
Usable tier (≥51 reviews)	9.6%	44K items	Embedding tốt
Long-tail (≤20 reviews)	71%	≈174K items	Embedding gần như random

Vấn đề thật sự không phải sparsity tổng thể

SVD và MF hoạt động được với sparsity 99% vì chúng học latent structure — không cần mỗi cell được fill. Vấn đề thật sự nằm ở chỗ phân phối sparsity không đều:

- **Head items (top 1%):** 1000+ reviews → embedding hội tụ tốt, model học được signal mạnh.
- **Tail items (bottom 80%):** 1-5 reviews → embedding chỉ là noise quanh global mean.
- **Cold users (1-2 reviews):** Model không thể phân biệt taste — fallback về popularity.

Đây chính là nguyên nhân coverage chỉ 1.56%: model dồn toàn bộ recommendations về top items có embedding tốt, hoàn toàn không động vào long-tail. Việc cải thiện RMSE thêm vài phần trăm không giải quyết được vấn đề cấu trúc này.

3.2 Đối chiếu với bài học Netflix Challenge

Dự án nghiên cứu lại Netflix Challenge (2006-2009) — cuộc thi đặt nền móng cho RecSys hiện đại — và rút ra ba bài học quan trọng:

- **Cải thiện RMSE ~1% là thực tế, không phải thất bại:** winning entry BellKor's Pragmatic Chaos chỉ cải thiện 10% RMSE sau ba năm tinh chỉnh. Kết quả -1.15% RMSE trên Amazon Electronics nằm trong phạm vi hợp lý.
- **RMSE không phản ánh chất lượng recommendation thực tế:** Netflix sau đó chuyển sang đánh giá bằng ranking metrics và engagement metrics vì RMSE không correlate tốt với satisfaction của user.
- **Ensemble luôn thắng:** Winning solution là ensemble 100+ models. Pipeline của dự án (4 models + Ridge ensemble) đi đúng hướng, nhưng độ lợi ích cận biên (marginal return) giảm rất nhanh khi thêm model.

Kết luận từ đối chiếu này: vấn đề không nằm ở thuật toán mà nằm ở đặc tính của dữ liệu Amazon. Cần một dataset có cấu trúc khác để pipeline phát huy giá trị.

3.3 Lý do chọn Goodreads

Sau khi phân tích nhiều dataset thay thế (MovieLens, Yelp, Last.fm, Goodreads), dự án chọn Goodreads UCSD Book Graph với các lý do cụ thể từ EDA:

Tiêu chí	Amazon Reviews	Goodreads UCSD
Quy mô tổng thể	≈233M reviews	≈229M interactions, 15.7M reviews (đủ big data theo CS246)
Distribution rating	Lệch nặng (5★ chiếm 65%)	Cân bằng hơn, có signal rõ ở rating thấp
Review length theo rating	1★ dài hơn 5★ (vent angry)	5★ (353 chars) > 1★ (315 chars) — book lovers viết dài khi yêu sách
User long-tail	Cực kỳ nặng (1-2 reviews)	Có cộng đồng heavy reader rõ ràng (>50 reviews)
Item long-tail	71% items ≤20 reviews	Phân phối đều hơn, ít item rác
Tín hiệu engagement	Chỉ rating + review text	Có n_votes (review được vote helpful) — signal CHƯA AI khai thác trong RecSys
Behavior chain	Không có (chỉ có rating)	shelve → read → rate → recommend (4 stage tự nhiên)
Multi-genre coverage	Mỗi category độc lập	10 genre có overlap, có bridge users đọc 3+ genre
Metadata phong phú	Title, brand, price	Title, author, publication_year, num_pages, genres, popular_shelves

Insights EDA quyết định cho Goodreads

Insight 1 – Review length đảo chiều: Trên Amazon, người tức giận viết dài để xả; trên Goodreads, ngược lại — 5 sao viết dài hơn 1 sao (353 vs 315 chars). Đây là vì Goodreads là mạng xã hội của book lovers — khi họ yêu một cuốn sách, họ phân tích, quote đoạn hay, recommend cho bạn bè. Insight này mở ra contribution chính của Phase 2: *review length có thể làm signal engagement*.

Insight 2 – n_votes là tín hiệu xã hội: Mỗi review trên Goodreads có thể được user khác vote là helpful. 15.7M votes thật từ con người, không cần annotation — đây là tín hiệu chất lượng review chưa được khai thác trong literature.

Insight 3 – Behavior chain monotonic: Hành vi user trên Goodreads có thứ tự tự nhiên (shelve → read → rate → recommend). Đây chính xác là cấu trúc mà chainRec (Wan & McAuley, RecSys'18) khai thác — dataset hoàn hảo cho Phase 3 mở rộng.

4. Phase 2 – Hệ thống gợi ý trên Goodreads UCSD Book Graph

4.1 Dữ liệu và quy trình xử lý

Goodreads UCSD Book Graph (Wan & McAuley, 2018) là dataset được scrape từ Goodreads với toàn bộ structure xã hội của platform: shelves, ratings, reviews, votes, comments. Dataset gốc có 6 file JSON.gz, tổng ≈ 16 GB.

Quy trình xử lý dữ liệu

Bước	Mô tả
1. Download raw	Tải các file JSON.gz: goodreads_interactions, reviews, books, authors, theo từng genre (10 genres)
2. Chunk parquet	Chuyển từ JSON.gz sang parquet partitioned by primary_genre, dùng PyArrow để tránh nổ RAM với file ~ 11 GB
3. Upload HuggingFace	Push lên hub vngclinh/goodreads-concats để tái sử dụng cross-session
4. Concat & dedupe	Hợp nhất reviews + interactions + books metadata bằng book_id
5. Schema fixes	Cast rating int, n_votes int, parse date_added $\rightarrow$ timestamp, drop rating=0 hoặc review_text null
6. Text cleaning	Strip HTML, unescape unicode, normalize whitespace, drop reviews < 10 tokens
7. Feature engineering	Compute vote_weight, edge_weight, bridge user detection, user stats
8. Temporal split	Train ≤ 2015 , Val 2016, Test 2017 (revised từ initial plan vì data không có 2018)
9. Cold-start filter	Giữ users có ≥ 5 train reviews
10. Upload preprocessed	vngclinh/goodreads-preprocessed (partitioned by genre)

Quy mô sau xử lý

Chỉ số	Giá trị
Số reviews	≈ 15.7 M (sau filter)
Số genres	10 (children, comics, fantasy, fiction, history, mystery, non-fiction, poetry, romance, young-adult)
Bridge users (≥ 3 genres)	Phát hiện qua 2-pass global stats
Train/Val/Test	Theo year: ≤ 2015 / 2016 / 2017

Chỉ số	Giá trị
LDA corpus	200K reviews/genre, vote-weighted sampling

Vấn đề kỹ thuật đã xử lý

Quá trình xử lý dữ liệu gặp nhiều khó khăn do quy mô, được giải quyết bằng các kỹ thuật sau:

- **RAM overflow khi load full dataset (~16GB):** chuyển sang incremental Counter từng file, del df sau mỗi file.
- **RAM overflow tại genre fantasy (~3.8GB):** chunk bằng `pq.ParquetFile.iter_batches(200k)` thay vì `pd.read_parquet` một lần.
- **User stats sai khi chạy per-genre:** tách thành 2-pass — pass 1 tính global stats (`user_review_count`, `genre_count`, `valid_users`), pass 2 mới process preprocessing per-genre.
- **Parse date_added không nhất quán:** format mixed 'Fri Dec 31...' thay vì ISO → dùng `pd.to_datetime(format='mixed')`.
- **HuggingFace path encoding:** `hf_hub_download` encode '=' thành '%3D' → chuyển sang `HfFileSystem.open()` và dùng `hf_fs.ls()` lấy `item['name']` trực tiếp.

4.2 Pipeline 4 phase

Phase	Vai trò	Output chính
Phase 1	EDA & Preprocessing	Cleaned parquet partitioned by genre, edge_weight column
Phase 2	Edge weighting ablation (5 công thức)	F1-F5 trained ALS models
Phase 3	LDA Taste Profile	user_taste_profile.parquet (50-dim per user)
Phase 4	ALS + Taste Blend + Eval	Final recommendations, Recall@K, NDCG@K

Phase 1 – EDA

Phát hiện distribution rating cân bằng hơn Amazon, review length tăng theo rating, và sự tồn tại của bridge users (users đọc ≥ 3 genres khác nhau). Visualize bằng heatmap genre-genre, t-SNE projection của user embeddings, popularity quartile analysis.

Phase 2 – Edge weighting (đóng góp chính)

Xây dựng ma trận user-book với 5 công thức weighting khác nhau, train ALS riêng cho mỗi công thức rồi so sánh ablation. Chi tiết kết quả ở Section 4.3.

Phase 3 – LDA Taste Profile

Train LDA trên review text với 40 topics, sample 200K reviews/genre (vote-weighted sampling). Mỗi user có một vector taste 50-dim: 40 dim topic distribution + 10 dim genre affinity. User taste profile = weighted average của book topic distributions với weight = $(\text{rating} - 3.5) \times \exp(-\lambda \times \text{days_ago})$.

Phase 4 – ALS + Taste Blend

Train ALS implicit với edge_weight làm confidence (theo công thức tốt nhất từ Phase 2). Với mỗi user, lấy top-100 candidate books từ ALS, sau đó re-rank bằng cosine similarity với taste profile:

$$\text{final_score} = \alpha \times \text{ALS_score} + (1 - \alpha) \times \text{taste_similarity}$$

α được tune trên validation set, kết quả tối ưu $\alpha = 0.7$ (ALS 70% + Taste 30%) nhất quán cho tất cả 5 variants edge weighting.

4.3 Ablation 5 công thức edge weighting (đóng góp chính)

Đây là contribution kỹ thuật chính của Phase 2: so sánh 5 công thức weighting cho edges trong ma trận user-book, đánh giá xem tín hiệu nào là tốt nhất để học từ Goodreads.

#	Tên	Công thức	Ý nghĩa
F1	vote_weighted	$\text{rating} \times \log(\text{votes}+1) / 5$	Vote đo quality của review

#	Tên	Công thức	Ý nghĩa
F2	rating_only	rating / 5	Baseline đơn giản
F3	rating_length	rating × log(length+1) / 5	Review dài = engagement cao
F4	combined	rating × log(votes+1) × log(length+1)	Kết hợp cả 3 tín hiệu
F5	binary	1 if rating ≥ 4 else 0	Baseline binary

Kết quả test set (sampled@500 evaluation)

Variant	Recall@10	NDCG@10	Recall@20	NDCG@20	vs F2
F3 ✓	0.6122	0.5369	0.6859	0.5597	+3.6%
F2	0.5757	0.5107	0.6447	0.5311	baseline
F5	0.5613	0.4995	0.6278	0.5189	-2.5%
F1	0.4744	0.4217	0.5448	0.4419	-17.6%
F4	0.4237	0.3752	0.4971	0.3961	-26.4%

Hai insights quan trọng

Insight A – Review length là tín hiệu engagement tốt nhất: F3 thắng tất cả với +3.6% so với rating-only. User viết review dài hơn = đã đọc kỹ, có suy nghĩ, có cảm xúc → tín hiệu preference đáng tin cậy hơn nhiều so với chỉ rating. Đây là điều mà literature hiện tại bỏ qua: hầu hết RecSys papers chỉ dùng rating hoặc binary interaction.

Insight B – n_votes gây popularity bias: F1 (dùng votes) thua F2 -17.6%, F4 (kết hợp tất cả) thua F2 -26.4%. Nguyên nhân: review của sách nổi tiếng tự nhiên có nhiều vote hơn (đơn giản vì có nhiều người đọc), nhưng điều này không có nghĩa rating của user đó đáng tin hơn. Khi dùng làm edge weight, votes inflate sách phổ biến và làm model ignore long-tail. Đây là một phản ví dụ ngược với intuition: tín hiệu xã hội rõ ràng không phải lúc nào cũng tốt.

Ablation alpha trên validation set (với F3)

Alpha	Blend	Recall@10 (val)	NDCG@10 (val)
1.0	ALS only (100%)	0.5831	0.5084
0.7 ✓	ALS 70% + Taste 30%	0.6054	0.5302
0.5	ALS 50% + Taste 50%	0.5912	0.5196
0.3	ALS 30% + Taste 70%	0.5643	0.4977

Alpha = 0.7 thắng nhất quán trên tất cả 5 variants — cho thấy ALS collaborative signal là chủ đạo, trong khi LDA taste signal đóng vai trò regularization bổ sung (+3.8% so với ALS-only).

4.4 Kết quả cuối cùng

Metric	Giá trị	Ý nghĩa
Recall@10	0.6122	~61% sách user thực sự thích có mặt trong top-10
Recall@20	0.6859	Mở rộng lên 20 thì có ~69%
NDCG@10	0.5369	Sách tốt có xu hướng xuất hiện ở top
NDCG@20	0.5597	Ranking quality ổn định khi mở rộng K

Honest limitations

Sampled@500 protocol overestimates performance: Với mỗi user, rank 1 positive + 500 random negatives → pool 501 thay vì full 1.3M books. Negatives được random sample, không phải hard negatives, nên metrics bị inflate so với full ranking. Số tuyệt đối 0.6122 không thể so trực tiếp với paper dùng full ranking (như paper gốc Wan & McAuley dùng AUC full ranking).

So sánh với literature

Method	Recall@10 (sampled)
Pure ALS (baseline)	~0.45–0.55
ALS + content features	~0.55–0.65
F3 của dự án	0.6122
SOTA graph-based (LightGCN)	~0.65–0.72

Kết quả của dự án nằm trong vùng ALS + content features, competitive nhưng chưa đạt SOTA graph-based. Quan trọng hơn số tuyệt đối là delta giữa các variants (F3 vs F2 = +3.6%) — đây mới là contribution thật sự.

5. Phase 3 (đang tiến hành) – Mở rộng với chainRec

5.1 Động lực

Phase 2 đạt kết quả competitive ($\text{Recall@10} = 0.6122$) nhưng ablation chỉ so sánh các variants ALS với nhau, chưa có baseline mạnh từ literature để chứng minh contribution. Việc kết hợp với chainRec (Wan & McAuley, RecSys'18 — paper tạo ra chính dataset Goodreads UCSD) cho phép:

- So sánh trực tiếp với paper gốc trên cùng dataset
- Khai thác structure monotonic chain (shelve → read → rate → recommend) tự nhiên của Goodreads
- Tạo contribution mới: combine review-length signal (F3) với behavior chain modeling

5.2 Trạng thái hiện tại

Bước	Trạng thái	Output
Phase 0 – Data loader (chainrec_data_loader.py)	Hoàn thành	48,307 users × 1,567,258 items × 13.7M interactions × 4 stages
Phase 1 – chainRec model (chainrec_model.py)	Đã code	PyTorch implementation: monotonic scoring + edgewise loss + uniform/stagewise samplers
Phase 1 – Training trên Kaggle GPU	Pending	Cần chạy trên Kaggle T4 với sample 50K users
Phase 2 – Contribution mới	Pending	Edge-weighted chainRec (Hướng A) + ALS hybrid (Hướng C)
Phase 3 – Multi-stage eval + demo	Pending	Recall/NDCG per stage, visualize embeddings

Stage distribution đã xác định

Stage	Số interactions	Tỷ lệ
stage 0 (shelve)	6,894,228	50.3%
stage 1 (read)	448,217	3.3% (drop-off lớn)
stage 2 (rate ≥1)	1,910,069	13.9%
stage 3 (recommend ≥4)	4,453,457	32.5%

Drop-off cực mạnh từ stage 0 (shelve) sang stage 1 (read) — chỉ ~6.5% sách được shelve thực sự được đọc — là pattern đặc trưng của Goodreads (user shelve để bookmark, không phải để đọc ngay). Đây là tín hiệu mà chainRec khai thác bằng monotonic scoring function.

5.3 Hai hướng contribution

Hướng A – Edge-weighted chainRec (kết hợp với F3)

Paper chainRec gốc treat tất cả edges như nhau trong edgewise loss. Đề xuất: weight $P(y_{l^*}=1, y_{l^*+1}=0)$ bằng engagement score (F3 từ review length). Hypothesis: edge transition của user viết review dài đáng tin hơn → cần được weight cao hơn trong loss function. Đây là cách kết hợp 2 contribution từ Phase 2 và chainRec.

Hướng C – ALS + chainRec hybrid

Extend alpha-blend logic từ Phase 2: $\text{final_score} = \alpha \times \text{ALS_score} + (1-\alpha) \times \text{chainRec_score}$. ALS giỏi capturing latent factors, chainRec giỏi monotonic ordering. Ensemble có thể outperform cả hai khi từng cái khai thác signal khác nhau.

6. Kết luận

6.1 Đóng góp đã đạt được

Dự án qua hai phase đã đạt được những kết quả cụ thể:

- **Phase 1 (Amazon):** Pipeline 5-stage hoàn chỉnh, ensemble winner ridge_positive đạt RMSE 1.1994 (Electronics) và 1.1358 (Home & Kitchen), nhưng quan trọng hơn là phát hiện được limitation cấu trúc của Amazon (1.56% catalog coverage, ranking metrics thất bại trên full catalog).
- **Phase 2 (Goodreads):** Pipeline 4-phase với contribution kỹ thuật chính là ablation 5 công thức edge weighting → phát hiện F3 (rating × log(length+1)) thắng baseline rating-only +3.6%, và phát hiện counter-intuitive rằng n_votes gây popularity bias (-17.6% đến -26.4%). Kết quả cuối: Recall@10 = 0.6122, NDCG@10 = 0.5369.
- **Bài học methodology:** validation OOF không đủ tin cậy cho model phức tạp (HGBR overfit ở cả 2 categories); Ridge đơn giản tổng quát tốt hơn; cải thiện RMSE ~1% là realistic theo Netflix Challenge; ranking metrics phản ánh chất lượng recommendation chính xác hơn RMSE.

6.2 Hạn chế hiện tại

- Cold-start chưa được đánh giá riêng (cả Amazon và Goodreads đều filter cold users ra)
- Goodreads dùng sampled@500 evaluation, không so trực tiếp được với paper dùng full ranking
- Phase 3 (chainRec) chưa training thật, chưa có kết quả số
- Demo hiện chỉ render 5000 books subset, không full catalog 1.35M

6.3 Bước tiếp theo

Thứ tự ưu tiên cho phần còn lại của dự án:

- **1. Training chainRec baseline** trên Kaggle GPU với sample 50K users để có số reference từ paper gốc.
- **2. Implement Hướng A (Edge-weighted chainRec)** — combine F3 signal với chainRec, đo improvement so với chainRec vanilla.
- **3. Implement Hướng C (ALS + chainRec hybrid)** — extend alpha-blend logic, kỳ vọng ensemble outperform cả hai.
- **4. Multi-stage evaluation:** đo Recall/NDCG cho từng stage riêng (shelve/read/rate/recommend), chứ không chỉ stage cuối.
- **5. Update demo:** thêm stage prediction (predict user sẽ shelve/read/rate/recommend), visualize learned embeddings theo stage.

Báo cáo này tổng hợp toàn bộ ba phase phát triển của dự án, từ Amazon Reviews ban đầu đến quyết định chuyển sang Goodreads và kế hoạch mở rộng với chainRec. Hành trình này minh họa rõ ràng một bài học CS246 quan trọng: chọn dataset phù hợp với bài toán quan trọng không kém việc chọn thuật toán phù hợp.